Clasificación de tumores cerebrales en cortes de resonancia magnética mediante una CNN

Angie Stefany Vera Medina, Gabriel Eduardo Moreno Veloza y Rubén Navarro Zenil

I. Introducción

La clasificación automática de imágenes de resonancia magnética (MRI) se estudia como apoyo al análisis radiológico. El problema abordado consiste en asignar cortes bidimensionales a cuatro categorías: glioma, meningioma, tumor hipofisario y sin tumor. La diversidad de planos, tamaños y apariencias plantea un reto para reconocer patrones que se mantengan en imágenes reservadas.

Las redes neuronales convolucionales (CNN) aprenden representaciones jerárquicas de las imágenes, como explican LeCun *et al.* [1]. En MRI cerebral, Badža y Barjaktarović [2] desarrollaron una CNN para tres tipos tumorales y examinaron cómo cambia su desempeño al separar imágenes o pacientes. Estos antecedentes sustentan el uso de convoluciones y la atención al protocolo de evaluación.

En este trabajo diseñamos, entrenamos y evaluamos una CNN en PyTorch para discriminar las cuatro clases. Incorporamos control de duplicados, particiones agrupadas y evaluación frente a una línea base mayoritaria. El alcance es clasificar cortes 2D; no se evalúan pacientes completos ni utilidad clínica.

II. Metodología

Datos y control de calidad. Se utilizó *Brain Tumor (MRI Scans)* de Kaggle, versión 1 [3], con 7023 imágenes. El inventario completo no detectó archivos ilegibles. Se retiraron 426 copias exactas por MD5, sin conflictos de etiqueta, conservando 6597 imágenes (Tabla I). El aHash convierte cada imagen a gris, la reduce a 16×16 y compara sus píxeles con la media. Sus coincidencias se usaron para agrupar, no para borrar: la inspección mostró imágenes distintas con el mismo hash, incluso en seis grupos con etiquetas diferentes.

TABLA I
Inventario y particiones tras eliminar duplicados.

Clase	Original	Limpio	Entr.	Val.	Prueba
Glioma	1621	1620	1134	243	243
Sin tumor	2000	1706	1196	255	255
Meningioma	1645	1531	1071	229	231
Hipofisario	1757	1740	1218	261	261
Total	7023	6597	4619	988	990

Partición. Con semilla 42, `StratifiedGroupKFold` formó 20 pliegues por grupos aHash, procurando conservar las proporciones de clase. Se asignaron 14 a entrenamiento, tres a validación y tres a prueba: 4619/988/990 imágenes, aproximadamente 70/15/15. Comprobamos que rutas, MD5 y aHash no coincidieran entre conjuntos. Usamos validación para monitorear el entrenamiento y reservamos prueba para evaluar el modelo final.

Transformaciones. Las imágenes se convirtieron a RGB y se redimensionaron a 128×128. Sobre tensores en $[0,1]$, se restó la media de cada canal (RGB: 0.1835, 0.1835 y 0.1836) y se dividió por su desviación estándar (0.1944 en los tres). Ambas estadísticas se calcularon solo con entrenamiento. En cada imagen de entrenamiento se aplicaron volteo horizontal ($p = 0.5$), rotación de $\pm 10°$, traslación de hasta 5 % y escala entre 0.95 y 1.05. En el espacio normalizado se añadió escala de intensidad uniforme en $[0.9, 1.1]$ y desplazamiento en $[-0.1, 0.1]$.

Arquitectura y entrenamiento. La CNN consta de tres bloques Conv(3×3, *padding* 1)–ReLU–MaxPool(2×2), con 32, 64 y 128 filtros. La salida $128 \times 16 \times 16$ se aplana y conecta a 256 unidades, ReLU, Dropout 0.5 [4] y cuatro logits. Esta arquitectura extrae patrones locales sin pesos preentrenados; Dropout busca limitar la coadaptación de las unidades densas. Entrenamos 8 483 140 parámetros con entropía cruzada sobre logits y Adam [5], tasa 10^{-3}, lotes de 32 y 15 épocas fijas, sin parada temprana. Evaluamos la época 15, sin seleccionarla mediante prueba. La ejecución registrada utilizó CPU, Python 3.12.14, PyTorch 2.5.1 y torchvision 0.20.1, con semillas 42.

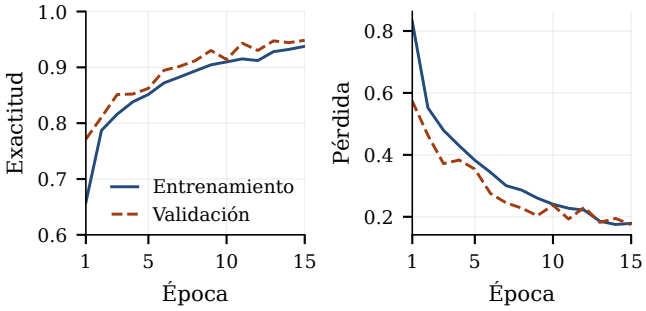


Fig. 1. Exactitud y pérdida por época. Azul continuo: entrenamiento con aumento de datos y Dropout; naranja discontinuo: validación sin ambos.

Evaluación. La exactitud mide la proporción de aciertos; precisión y *recall* distinguen falsas asignaciones y casos omitidos por clase. F1 macro combina precisión y *recall* dando igual peso a cada categoría; F1 ponderado considera su soporte. La matriz de confusión permite localizar errores, incluidos tumores clasificados como sin tumor. La línea base predice siempre la clase más frecuente en entrenamiento: hipofisario.

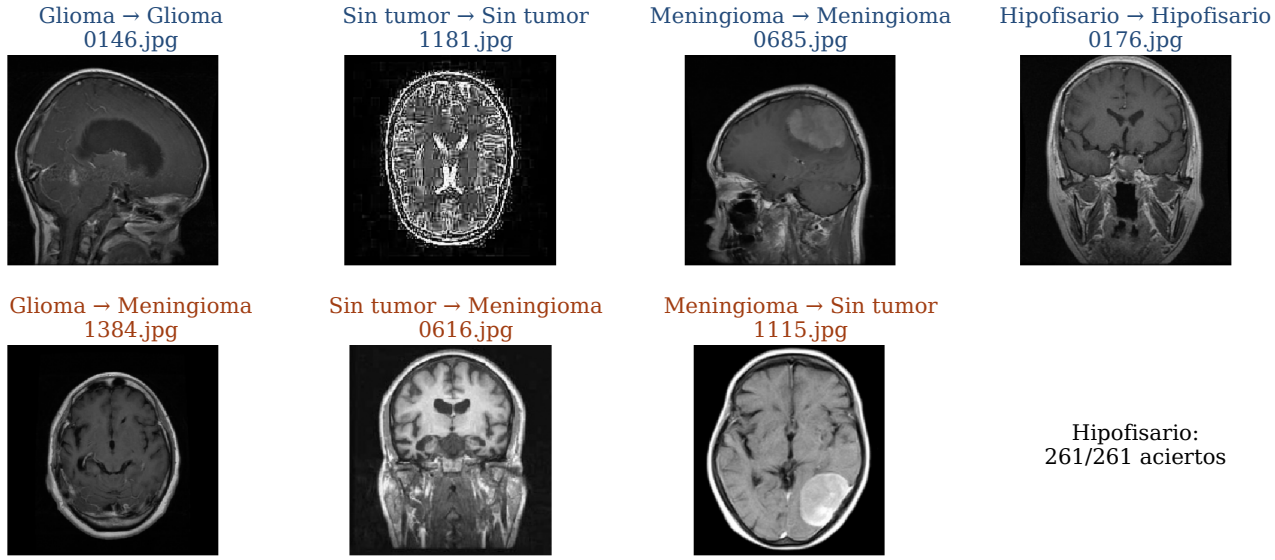


Fig. 2. Ejemplos de clasificación en el conjunto de prueba. Cada panel indica clase real → predicción y archivo. Arriba: un acierto por clase; abajo: un error por clase cuando existe. La selección se realizó con semilla 42. No hubo falsos negativos en la clase hipofisario.

III. Resultados

La CNN obtuvo 95.05 % de exactitud (941/990), F1 macro 0.9492 y F1 ponderado 0.9503. La línea base alcanzó 26.36 % y F1 macro 0.1043; la diferencia de exactitud fue 68.69 puntos porcentuales. La Tabla II presenta las métricas por clase. De 49 errores (Fig. 3), 16 fueron glioma → meningioma, diez meningioma → hipofisario y nueve meningioma → sin tumor.

TABLA II
Métricas en prueba (escala 0–1). El soporte es el número de imágenes de cada clase.

Clase	Precisión	Recall	F1	Soporte
Glioma	0.9825	0.9259	0.9534	243
Sin tumor	0.9647	0.9647	0.9647	255
Meningioma	0.9087	0.9048	0.9067	231
Hipofisario	0.9457	1.0000	0.9721	261

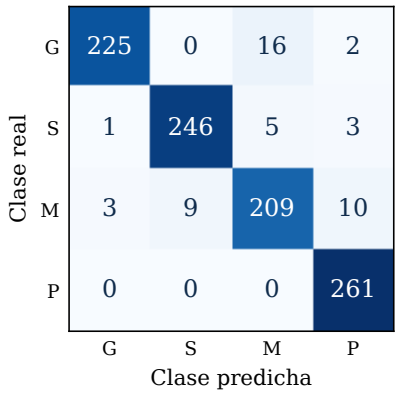


Fig. 3. Matriz de confusión en 990 imágenes de prueba: filas reales y columnas predichas. G: glioma; S: sin tumor; M: meningioma; P: hipofisario. Los valores son conteos absolutos.

Las pérdidas descendieron de 0.8301 a 0.1787 en entrenamiento y de 0.5735 a 0.1746 en validación, cuyo mínimo ocurrió en la época 15 (Fig. 1). Las exactitudes finales fueron 93.76 % y 94.84 %, respectivamente; la pérdida de prueba fue 0.1664. La Fig. 2 permite contrastar aciertos y errores con las etiquetas originales.

IV. Discusión

Superar la regla mayoritaria evidencia discriminación entre clases en esta partición. Meningioma presentó el menor F1: combina omisiones con falsas asignaciones procedentes de otras clases. El *recall* hipofisario de 1.0000 coexistió con precisión 0.9457, porque otros tumores y cortes sin tumor fueron asignados a esa categoría. Los nueve meningiomas clasificados como sin tumor merecen revisión, aunque los ejemplos no identifican la causa anatómica ni los rasgos utilizados por la red.

Las curvas no muestran una divergencia sostenida que permita afirmar sobreajuste durante las 15 épocas. La exactitud de validación superior a la de entrenamiento es compatible con condiciones distintas: entrenamiento incluye perturbaciones y Dropout, desactivados al evaluar [4]. Sin ablaciones, no podemos atribuir mejoras a cada componente.

La agrupación por aHash reduce coincidencias comprobadas entre particiones, pero puede reunir imágenes diferentes y omitir variantes similares. Sin identificadores no se garantiza separación por paciente. La diferencia entre evaluación por imagen y por sujeto señalada en [2] refuerza esta limitación; sus cifras no son directamente comparables por utilizar otra base y protocolo. Una sola corrida no permite estimar variabilidad entre semillas. Tampoco se evaluaron centros externos, volúmenes 3D ni validez clínica. Antes de ampliar la arquitectura, conviene priorizar una partición por paciente, una prueba externa y revisión experta de los errores de meningioma.

REFERENCIAS

[1] Y. LeCun, Y. Bengio y G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015, doi: 10.1038/nature14539.

[2] M. M. Badža y M. Č. Barjaktarović, "Classification of brain tumors from MRI images using a convolutional neural network," *Applied Sciences*, vol. 10, no. 6, art. 1999, 2020, doi: 10.3390/app10061999.

[3] rm1000, "Brain Tumor (MRI Scans)," Kaggle, versión 1, conjunto de datos. [En línea]. Disponible: https://www.kaggle.com/datasets/rm1000/brain-tumor-mri-scans. [Consulta: 2-nov-2026].

[4] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever y R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014. [En línea]. Disponible: https://jmlr.org/papers/v15/srivastava14a.html.

[5] D. P. Kingma y J. Ba, "Adam: A method for stochastic optimization," en *Proc. International Conference on Learning Representations (ICLR)*, 2015. [En línea]. Disponible: https://arxiv.org/abs/1412.6980.